



CAHIER DE SPÉCIFICATIONS

Application de Parsing Intelligent de CVs

Destinataire	Stagiaire développeur - KINOVATECH
Rédacteur	Responsable Dépt. IA - KINOVATECH
Version	v1.0 - Juillet 2026
Statut	Document de référence projet
Confidentialité	Usage interne restreint

1. Introduction et Contexte du Projet

1.1 Contexte du Projet

Le marché marocain des ressources humaines connaît une digitalisation accélérée. Les cabinets RH reçoivent quotidiennement des centaines, voire des milliers de candidatures sous forme de fichiers PDF, Word ou images scannées. Le traitement manuel de ces documents est chronophage, source d'erreurs et peu scalable.

Le présent projet vise à développer une application de parsing intelligent de CVs, capable d'extraire, de structurer et d'analyser automatiquement les informations contenues dans des CV hétérogènes, tout en respectant scrupuleusement le cadre légal marocain de protection des données personnelles (Loi 09-08 et ses amendements).

1.3 Objectifs Généraux

- Automatiser l'extraction d'informations structurées à partir de CVs multi-formats
- Garantir la conformité RGPD/Loi 09-08 dans le traitement des données personnelles
- Mettre en œuvre une architecture hybride combinant IA discriminative, règles déterministes et LLM
- Fournir une API REST consommable par les systèmes existants des cabinets RH
- Permettre la recherche, le filtrage et le scoring des candidats

1.4 Périmètre du Document

Ce cahier de spécifications est destiné au stagiaire développeur affecté au projet au sein de KINOVATECH. Il constitue la référence technique et fonctionnelle unique pour la conception, le développement et la validation de l'application. Il couvre :

- Les spécifications fonctionnelles détaillées (SF)
- Les spécifications non-fonctionnelles (SNF)
- L'architecture technique et les choix technologiques
- Les contraintes légales et éthiques
- Les livrables attendus et les critères de validation

 *Ce document est classé usage interne restreint. Toute diffusion externe requiert l'accord explicite de la Direction IT de KINOVATECH.*

2. Analyse du Besoin

Cas d'Usage Principaux

UC-01 : Import et Parsing d'un CV

- L'utilisateur (cabinet RH) télécharge un CV (PDF, DOCX, JPG, PNG)
- Le système extrait automatiquement toutes les informations structurées
- Le résultat est présenté sous forme de fiche candidat structurée
- Les données personnelles sont marquées et traitées selon le pipeline sécurisé

UC-02 : Traitement par Lot (Batch)

- Import d'un dossier ZIP contenant jusqu'à 500 CVs
- Traitement asynchrone avec file de priorité
- Tableau de bord de suivi en temps réel
- Export CSV/JSON des résultats consolidés

UC-03 : Recherche et Filtrage

- Recherche full-text sur les CVs parsés
- Filtres multicritères : compétences, expérience, formation, localisation
- Tri par score de pertinence (matching avec une fiche de poste)

UC-04 : Anonymisation pour Audit / Tests

- Génération d'un CV anonymisé (données personnelles masquées)
- Traçabilité de l'anonymisation dans un journal d'audit

3. Spécifications Fonctionnelles (SF)

3.1 Module 1 — Ingestion et Pré-traitement des Documents

SF-01 : Formats Acceptés

L'application doit accepter les formats de fichiers suivants :

Format	Extension	Traitement Requis
PDF texte natif	.pdf	Extraction directe via pdfplumber / PyMuPDF
PDF scanné	.pdf	OCR obligatoire (Tesseract 5 / EasyOCR)
Word moderne	.docx	Extraction python-docx
Word ancien	.doc	Conversion via LibreOffice headless
Image	.jpg, .jpeg, .png, .tiff	OCR + débruitage image
RTF	.rtf	Conversion puis extraction texte

SF-02 : Détection de la Langue

Le système doit détecter automatiquement la langue du CV (arabe, français, anglais) via la bibliothèque langdetect ou lingua-py, et adapter le pipeline de traitement en conséquence.

 Les CVs en arabe nécessitent un traitement spécifique : lecture droite-gauche, normalisation Unicode (NFKC), tokenisation adaptée (cameltools ou farasapy).

SF-03 : Nettoyage et Normalisation

- Suppression des en-têtes/pieds de page redondants
- Normalisation des espaces, tabulations et caractères spéciaux
- Détection et suppression des filigranes et annotations
- Unification des encodages (UTF-8)

3.2 Module 2 — Pipeline de Parsing Hybride

Le cœur fonctionnel de l'application repose sur une architecture de parsing à trois couches complémentaires :

SF-04 : Couche 1 — Règles Déterministes (Données Personnelles)

Cette couche traite en priorité les données personnelles identifiables (PII). Elle est basée sur des expressions régulières robustes et des dictionnaires contextuels.

Champ	Méthode Déterministe	Exemple Regex / Règle
Téléphone Maroc	Regex	/(\+212 0)([\-]?) (5 6 7)\d{8}/
Email	Regex RFC 5322	/[a-zA-Z0-9._%+-]+@[a-zA-Z0-9.-]+\.[a-z]{2,}/
CIN Marocain	Regex	/[A-Z]{1,2}[0-9]{5,6}/
Date de naissance	Regex + contexte	/(né born date de naissance).*(\d{2}[\V-]\d{2}[\V-]\d{4})/i
Adresse Maroc	Dictionnaire villes + regex	Casablanca, Rabat, Marrakech... + code postal
Nationalité	Liste blanche + contexte	Tokens après "nationalité:", "nationality:"

Champ	Méthode Déterministe	Exemple Regex / Règle
LinkedIn / GitHub	Regex URL	/(linkedin github)\.com\[a-zA-Z0-9_]+\

 Toutes les données extraites par cette couche sont immédiatement marquées comme PII=true dans le modèle de données. Elles bénéficient du traitement sécurisé décrit en Section 5.

SF-05 : Couche 2 — IA Discriminative (NER & Classification)

Cette couche utilise des modèles de NER (Named Entity Recognition) pré-entraînés et fine-tunés pour extraire les entités non-personnelles structurées du CV.

Entité Cible	Modèle IA	Bibliothèque
Intitulés de postes	camemBERT fine-tuné (FR) / AraBERT (AR)	transformers (HuggingFace)
Compétences techniques	Classifier multi-label + ontologie skills	scikit-learn + spaCy
Noms d'entreprises	NER ORGANISATION	spaCy fr_core_news_lg
Établissements d'enseignement	NER ORG + dictionnaire écoles Maroc	spaCy + custom EntityRuler
Diplômes / Certifications	Pattern matching + classificateur	spaCy + regex hybride
Durées d'expérience	Extraction temporelle (NER DATE)	spaCy + dateparser
Secteurs d'activité	Classifier texte (TF-IDF + SVM)	scikit-learn

SF-06 : Couche 3 — LLM pour l'Inférence Sémantique

Le LLM intervient uniquement sur des données NON personnelles, masquées ou agrégées. Son rôle est d'enrichir sémantiquement les résultats des couches précédentes.

Tâche LLM	Description	Données en entrée
Résumé de profil	Génération d'un résumé professionnel synthétique	Texte anonymisé uniquement
Inférence de soft skills	Déduction de compétences transverses depuis le texte	Description expériences masquées
Normalisation compétences	Mapping vers ontologie standard (ESCO, ROME)	Liste de compétences brutes
Scoring matching poste	Évaluation adéquation CV ↔ fiche de poste	CV anonymisé + JD
Détection incohérences	Signalement de dates chevauchantes, lacunes	Timeline expériences
Classification secteur	Affectation à une taxonomy sectorielle	Titres postes agrégés

Au lieu de s'appuyer uniquement sur ESCO, prévoir dès le départ une table **skills_ontology** en base de données avec trois colonnes :

label_brut | source | uri_normalisé
 "Python" | ESCO | esco.uri/skill/python
 "Ingénieur EMI" | CUSTOM_MA | custom/diplome/emi
 "Chargé recouvrement" | CUSTOM_MA | custom/metier/recouvrement

⚠ RÈGLE ABSOLUE : Le LLM ne reçoit JAMAIS de données personnelles brutes (nom, prénom, email, téléphone, CIN, adresse). Un mécanisme de vérification automatique pré-LLM est obligatoire.

3.3 Module 3 — Modèle de Données Structuré en Sortie

SF-07 : Schéma JSON de Sortie

Chaque CV parsé génère un objet JSON normalisé selon le schéma suivant :

```
{ "cv_id": "uuid-v4", "processing_timestamp": "ISO-8601", "source_format":
"pdf|docx|image", "language_detected": "fr|ar|en", "pii_fields": {
  "nom_complet": {"value": "...", "masked": false, "confidence": 0.98},
  "email": {"value": "...", "masked": false, "confidence": 0.99},
  "telephone": {"value": "...", "masked": false, "confidence": 0.95},
  "adresse": {"value": "...", "masked": false, "confidence": 0.87},
  "date_naissance": {"value": "...", "masked": false, "confidence": 0.92},
  "cin": {"value": "...", "masked": false, "confidence": 0.96} },
  "profil": {
    "titre_poste_actuel": "...", "annees_experience_totale": 7,
    "secteur_principal": "...", "resume_genere_llm": "...",
    "experiences": [{ "entreprise": "...", "date_debut": "YYYY-MM",
    "date_fin": "YYYY-MM", "duree_mois": 24,
    "description_masquee": "...", "soft_skills_inferes": ["leadership", "gestion de
    projet"] }], "formations": [{ "etablissement": "...", "diplome": "...",
    "domaine": "...", "annee_obtention": 2018, "niveau_rncp_equivalent": "Bac+5" }],
    "competences": {
      "techniques": [{"label": "Python", "niveau": "expert", "source":
      "declaratif"}],
      "langues": [{"langue": "Français", "niveau": "C1"}],
      "certifications": [{"label": "AWS Solutions Architect", "date": "2023-06"}] },
    "scores": {
      "completude_cv": 0.87, "coherence_temporelle": 0.95,
      "matching_score": null },
    "audit_trail": {
      "pipeline_version": "1.0",
      "layers_applied": ["deterministic", "ner", "llm"],
      "processing_time_ms": 1250 }
```

3.4 Module 4 — Interface Utilisateur Web

SF-08 : Dashboard Cabinet RH

- Vue liste des CVs importés avec statut de traitement
- Filtres avancés : compétences, expérience min/max, formation, localisation, langue
- Visualisation de la fiche candidat structurée (lecture seule)
- Actions : télécharger JSON, exporter CSV, anonymiser, archiver

SF-09 : Import et Suivi

- Upload unitaire ou batch (ZIP, max 500 fichiers, 50 Mo)
- Barre de progression en temps réel (WebSocket)
- Notification email/webhook à la fin du traitement batch
- Journal des erreurs avec fichiers non-traitables identifiés

SF-10 : API REST

Endpoint	Méthode	Description
/api/v1/cvs/upload	POST	Upload et parsing d'un CV unitaire
/api/v1/cvs/batch	POST	Import batch (ZIP)

Endpoint	Méthode	Description
/api/v1/cvs/{id}	GET	Récupération d'un CV parsé
/api/v1/cvs/search	POST	Recherche full-text + filtres
/api/v1/cvs/{id}/anonymize	POST	Anonymisation d'un CV
/api/v1/cvs/{id}/match	POST	Scoring matching avec une JD
/api/v1/health	GET	Health check

4. Spécifications Non-Fonctionnelles (SNF)

4.1 Performance

Exigence	Indicateur	Valeur Cible
Temps de parsing unitaire (PDF texte)	Latence P95	< 3 secondes
Temps de parsing (PDF scanné + OCR)	Latence P95	< 15 secondes
Débit batch	Throughput	≥ 50 CVs/minute
Temps de réponse API	Latence P95	< 500 ms (hors parsing)
Charge simultanée	Utilisateurs concurrents	≥ 20 utilisateurs
File de traitement	Taille max file	10 000 jobs

4.2 Précision et Qualité

Entité	Méthode d'Extraction	Précision Minimale
Email, Téléphone, CIN	Regex déterministe	≥ 99%
Nom complet	NER + règles	≥ 95%
Intitulés de postes	NER camemBERT	≥ 88%
Compétences techniques	Classifier + ontologie	≥ 85%
Dates d'expérience	NER DATE + dateparser	≥ 92%
Diplômes / Formations	Hybride NER + regex	≥ 87%
OCR (qualité scan correcte)	Tesseract 5	≥ 95% CER

 La précision est mesurée sur un jeu de test de 200 CVs annotés manuellement, représentatif de la diversité des formats marocains.

4.3 Sécurité

SNF-03 : Sécurité Applicative

- Authentification JWT (RS256) avec expiration à 1h, refresh token 7 jours
- Autorisation basée sur les rôles : ADMIN, CABINET_RH, LECTEUR
- Rate limiting : 100 requêtes/minute par client
- Validation stricte des uploads (type MIME, magic bytes, taille, nom de fichier)
- Scan antivirus des fichiers uploadés (ClamAV intégré)
- Protection OWASP Top 10 : injection, XSS, CSRF, IDOR
- Chiffrement TLS 1.3 obligatoire sur toutes les communications

SNF-04 : Sécurité des Données PII

- Chiffrement AES-256 au repos pour tous les champs PII
- Séparation physique : données PII dans une base dédiée (PII Store)
- Accès aux PII journalisé (qui, quand, quelle donnée)

- Droit à l'oubli : API d'effacement complet avec confirmation
- Durée de rétention configurable par cabinet (défaut : 12 mois)

4.4 Disponibilité et Fiabilité

- Disponibilité cible : 99,5% (hors fenêtres de maintenance planifiées)
- Fenêtre de maintenance : samedi 02h00–06h00 GMT+1
- Sauvegarde base de données : quotidienne, rétention 30 jours
- Reprise après incident (RTO) : < 4 heures
- Perte de données maximale acceptable (RPO) : < 1 heure
- Health check automatique toutes les 30 secondes

4.5 Scalabilité

- Architecture microservices containerisée (Docker + Docker Compose en dev, Kubernetes en prod)
- File de messages asynchrone (Celery + Redis) pour le parsing batch
- Scalabilité horizontale des workers de parsing indépendamment de l'API
- Base de données : PostgreSQL avec partitioning sur date d'import
- Stockage fichiers : compatible S3 (Minio en dev, AWS S3 ou OVH Object Storage en prod)

4.6 Maintenabilité

- Coverage de tests unitaires $\geq 80\%$ (pytest + coverage.py)
- Tests d'intégration sur les endpoints API (pytest + httpx)
- Documentation automatique de l'API (OpenAPI 3.0 / Swagger UI)
- Linting obligatoire : ruff (Python), ESLint (JS/TS)
- Versionning sémantique (SemVer 2.0) pour l'API et les releases
- Logs structurés JSON (structlog) avec niveaux DEBUG/INFO/WARNING/ERROR
- Monitoring : Prometheus (métriques) + Grafana (dashboards)

4.7 Portabilité

- Déploiement possible sur : serveur Linux (Ubuntu 22.04+), AWS, Azure, OVH
- Scripts d'installation automatisée (Makefile + docker-compose.yml)
- Variables d'environnement documentées dans un fichier .env.example
- Support multi-tenant : isolation par cabinet RH dès la conception

5. Conformité Légale et Éthique

5.1 Cadre Légal Marocain — Loi 09-08

La Loi n° 09-08 relative à la protection des personnes physiques à l'égard des traitements des données à caractère personnel constitue le cadre légal de référence. Son application est contrôlée par la Commission Nationale de Contrôle de la Protection des Données à Caractère Personnel (CNDP).

Obligation Légale	Mesure Technique Appliquée
Déclaration préalable à la CNDP	Registre des traitements fourni en livrables
Finalité explicite et légitime	Traitement limité au matching emploi (purpose binding)
Consentement éclairé	Bandeau de consentement + logs de consentement
Droit d'accès du candidat	API /candidates/{id}/export accessible sur demande
Droit de rectification	Interface de correction manuelle des données parsées
Droit à l'effacement	API /candidates/{id}/delete avec confirmation double
Sécurité des données	Chiffrement AES-256, TLS 1.3, audit log
Transfert international de données	Interdit sans accord CNDP explicite — LLM on-premise ou données masquées

5.2 Principe de Privacy by Design

- Minimisation des données : seules les données strictement nécessaires au matching sont extraites
- Pseudonymisation systématique avant tout traitement LLM ou analytique
- Séparation des données PII et non-PII dès l'ingestion
- Durée de rétention minimale avec suppression automatique après expiration

5.3 Utilisation des LLM et Données Personnelles

● RÈGLE CRITIQUE — OBLIGATION ABSOLUE : *Aucune donnée à caractère personnel (nom, prénom, email, téléphone, CIN, adresse, date de naissance) ne doit transiter vers un LLM externe (OpenAI, Anthropic Cloud, etc.). Le LLM doit être utilisé uniquement sur des données masquées, agrégées ou synthétiques.*

Options architecturales conformes :

- LLM On-Premise : déploiement local de Llama 3, Mistral 7B ou Qwen via Ollama (**OPTIONNEL**)
- LLM Cloud avec anonymisation préalable : masquage certifié des PII avant envoi via API
- Contrat DPA (Data Processing Agreement) obligatoire avec tout fournisseur LLM cloud

5.4 Biais Algorithmiques

- Le système ne doit en aucun cas filtrer ou scorer les candidats sur des critères discriminants (genre, âge, origine, religion)
- Les champs protégés (date de naissance, photo) sont masqués par défaut dans le scoring
- Un audit de biais doit être réalisé trimestriellement sur les résultats de scoring

6. Architecture Technique

6.1 Vue d'Ensemble de la Stack

Couche	Technologie	Rôle
API Backend	FastAPI (Python 3.11+)	API REST + orchestration pipeline
Worker Async	Celery 5 + Redis 7	Traitement asynchrone des CVs
OCR	Tesseract 5 + EasyOCR	Reconnaissance optique de caractères
NLP / NER	spaCy 3.7 + HuggingFace Transformers	Extraction entités nommées
ML Classification	scikit-learn 1.4	Classifieurs compétences, secteurs
LLM	GPT-4o-mini	Inférence sémantique sur données masquées
Base de Données	PostgreSQL 16	Stockage structuré + recherche full-text
Base PII	PostgreSQL 16 (instance séparée)	Stockage isolé données personnelles
Stockage Fichiers	MinIO (dev) / S3 (prod)	Stockage CVs bruts chiffrés
Cache	Redis 7	Cache résultats + sessions
Frontend	React 18 + TypeScript + TailwindCSS	Interface utilisateur cabinet RH
Containerisation	Docker + Docker Compose	Déploiement reproductible
Monitoring	Prometheus + Grafana	Métriques et alertes

6.2 Flux de Traitement d'un CV (Pipeline Détaillé)

Le pipeline suit les étapes séquentielles suivantes :

Éta pe	Module	Technologie	Sortie
1. Réc epti on	API Upload	FastAPI + Multipart	Fichier stocké (MinIO), job_id retourné
2. Vali dati on	File Validator	python-magic	Fichier validé ou rejeté
3. Mis e en file	Queue Manager	Celery + Redis	Job en attente d'exécution
4. Extr acti on text e	Text Extractor	Pymupdf / python-docx / Tesseract	Texte brut segmenté

Étape	Module	Technologie	Sortie
5. Détection langue	Lang Detector	lingua-py	Code langue (fr/ar/en)
6. Détection PII	PII Detector	Regex + dictionnaires	Entités PII localisées + spans
7. NER Non-PII	NER Engine	spaCy + camemBERT	Entités professionnelles
8. Masquage PII	PII Masker	Custom Python	Texte anonymisé pour LLM
9. Enrichissement LLM	LLM Enricher	GPT-4o-mini	Résumé, soft skills, matching
10. Structuration	JSON Builder	Pydantic v2	Objet JSON valide
11. Stockage	Data Store	PostgreSQL + MinIO	CV parsé persisté
12. Notification	Notifier	WebSocket + Email	Statut renvoyé à l'utilisateur

6.3 Environnement de Développement du Stagiaire

L'environnement de développement local sera fourni clé en main :

- Repository Git privé avec accès en lecture/écriture
- docker-compose.yml préconfiguré (PostgreSQL, Redis, MinIO)
- Makefile avec commandes : make dev, make test, make lint, make docs
- Jeu de données de test : 50 CVs anonymisés et annotés
- Collection Bruno pour tester l'API
- Variables d'environnement documentées dans .env.example

7. Livrables Attendus et Planification

7.1 Livrables Techniques

Livrable	Description
L-01 : Environnement configuré	Docker Compose fonctionnel + README installation
L-02 : Module OCR + extraction texte	Pipeline multi-format opérationnel
L-03 : Couche déterministe PII	Regex + tests unitaires (coverage $\geq 80\%$)
L-04 : Couche NER Non-PII	Modèles spaCy intégrés + évaluation
L-05 : Intégration LLM	prompts + mécanisme de masquage
L-06 : API REST FastAPI	Endpoints documentés (OpenAPI)
L-07 : Interface Frontend	Dashboard React (import, liste, fiche)
L-08 : Tests & Validation	Rapport de précision sur jeu de test
L-09 : Documentation technique	Architecture, API, guide déploiement
L-10 : Registre CNDP	Registre des traitements conforme Loi 09-08
L-11 : Démo finale	Présentation + rapport de stage

7.2 Critères de Validation et Recette

Critères Fonctionnels

- Parsing correct d'au moins 90% des CVs du jeu de test
- Précision NER $\geq$ seuils définis en Section 4.2
- Aucune donnée PII envoyée au LLM (vérification automatisée)
- Tous les endpoints API documentés et fonctionnels
- Batch de 100 CVs traité en moins de 5 minutes

Critères Non-Fonctionnels

- Coverage de tests $\geq 80\%$
- Documentation API complète (OpenAPI valide)
- Application déployable depuis docker-compose up en moins de 2 minutes
- Aucune vulnérabilité critique détectée (scan Bandit + pip-audit)

8. Contraintes et Gestion des Risques

8.1 Contraintes du Projet

- Budget infrastructure limité : favoriser les solutions open-source
- IA On-Premise / déterministe obligatoire pour les données non anonymisées
- Conformité Loi 09-08 non négociable — bloque la mise en production
- Support des CVs en arabe dès la version 1 (non optionnel pour le marché marocain)

8.2 Registre des Risques

Risque	Probabilité	Impact	Mitigation
CVs très hétérogènes (qualité scan faible)	Élevée	Moyen	Prétraitement image + seuil de confiance OCR
Dérive du scope (feature creep)	Moyenne	Élevé	Réunion hebdomadaire avec Direction IT
Fuite de données PII vers le LLM	Faible	Critique	Tests automatiques pré-LLM obligatoires
Modèles NER peu performants en arabe	Moyenne	Moyen	AraBERT + données d'entraînement marocaines
Indisponibilité de l'environnement dev	Faible	Moyen	Snapshots Docker quotidiens

9. Glossaire

Terme	Définition
CV	Curriculum Vitae — document de candidature d'un individu
PII	Personally Identifiable Information — données à caractère personnel
NER	Named Entity Recognition — reconnaissance d'entités nommées (IA)
OCR	Optical Character Recognition — reconnaissance optique de caractères
LLM	Large Language Model — modèle de langage de grande taille (GPT, Llama, Mistral...)
TALN	Traitement Automatique du Langage Naturel (NLP en anglais)
CNDP	Commission Nationale de contrôle de la protection des Données à caractère Personnel (Maroc)
Loi 09-08	Loi marocaine relative à la protection des données personnelles
ESCO	European Skills, Competences, Qualifications and Occupations — ontologie européenne des compétences
ROME	Répertoire Opérationnel des Métiers et des Emplois (France Travail)
DSI	Direction des Systèmes d'Information
JD	Job Description — fiche de poste
API REST	Interface de programmation applicative suivant l'architecture REST
JWT	JSON Web Token — standard d'authentification par jeton
DPA	Data Processing Agreement — accord de traitement des données
Fine-tuning	Ajustement fin d'un modèle IA pré-entraîné sur des données spécifiques
Regex	Expression régulière — motif de correspondance de chaînes de caractères

10. Annexes

Annexe A — Dépendances Python Recommandées

```
# requirements.txt — Application de Parsing de CVs KINOVATECH

# Framework

APIfastapi==0.111.0

uvicorn[standard]==0.30.1

pydantic[email]==2.7.1

# Traitement de documents

pdfplumber==0.11.1

PyMuPDF==1.24.4

python-docx==1.1.2

Pillow==10.3.0

# OCR

pytesseract==0.3.10

easyocr==1.7.1

# NLP / NER

spacy==3.7.4

transformers==4.41.2

torch==2.3.0

scikit-learn==1.4.2

lingua-language-detector==2.0.2

camel-tools==1.5.2

# Arabe NLP

dateparser==1.2.0

# Pipeline asynchrone

celery==5.4.0redis==5.0.4

# Base de données

sqlalchemy==2.0.30

alembic==1.13.1

asyncpg==0.29.0

psycopg2-binary==2.9.9

# Stockage

boto3==1.34.120          # Compatible MinIO / S3

# Sécurité

python-jose[cryptography]==3.3.0

passlib[bcrypt]==1.7.4
```

```
python-multipart==0.0.9

# Monitoring / Logs

prometheus-fastapi-instrumentator==7.0.0

structlog==24.2.0

# Tests

pytest==8.2.1

pytest-asyncio==0.23.7

httpx==0.27.0

coverage==7.5.3

# Qualité code

ruff==0.4.7

bandit==1.7.8
```

Annexe B — Modèles IA Recommandés (NLP)

Modèle	Usage	Licence	Source
fr_core_news_lg	NER Français (spaCy)	MIT	spacy.io
camembert-base	Classification/NER Français	MIT	HuggingFace
CAMEL-Lab/bert-base-arabic-camelbert-ca-ner	NER Arabe	Apache 2.0	HuggingFace
intfloat/multilingual-e5-large	Embeddings multilingues	MIT	HuggingFace

Annexe C — Ressources et Références

- Loi 09-08 Maroc : <https://cndp.ma/legislation>
- spaCy Documentation : <https://spacy.io/docs>
- HuggingFace Hub : <https://huggingface.co>
- FastAPI Documentation : <https://fastapi.tiangolo.com>
- ESCO API : <https://esco.ec.europa.eu/en/use-esco/esco-api>
- OWASP Top 10 : <https://owasp.org/www-project-top-ten>

Fin du document — KINOVATECH — Direction IT — Juillet 2026
Document soumis à confidentialité. Reproduction interdite sans accord écrit.