

RAPPORT DE STAGE À DISTANCE (REMOTE)

Conception, Développement et Déploiement d'une Application de Parsing Intelligent de CVs,
Anonymisation PII (Loi 09-08 CNDP) et Dashboard RH Moderne

Réalisé par :	YOUSSEF TAICHA
Filière :	Diplôme Universitaire de Technologie (DUT) Génie Informatique
Établissement :	EST Meknès — Université Moulay Ismaïl (UMI)
Entreprise d'Accueil :	KINOVATECH (Dépt. IA & Direction IT)
Modalité du Stage :	À Distance / Remote (Télétravail)
Encadrant Entreprise :	Responsable Dépt. IA (KINOVATECH)
Encadrant Pédagogique :	Prof. A. ABOULFARAJ (EST Meknès)
Année Universitaire :	2025 / 2026

REMERCIEMENTS

Avant d'entamer la présentation technique de ce rapport de stage réalisé à distance, il m'est particulièrement agréable d'adresser mes remerciements les plus sincères à Monsieur le Directeur de l'**École Supérieure de Technologie de Meknès (ESTM - UMI)** ainsi qu'à l'ensemble des enseignants et formateurs du département **Génie Informatique** pour la rigueur, l'excellence et la qualité de la formation académique dispensée tout au long de mon cursus universitaire.

Je tiens à exprimer ma gratitude la plus vive à mon encadrant pédagogique à l'EST Meknès, **Monsieur le Professeur A. ABOULFARAJ**, pour son suivi constant, sa rigueur méthodologique, ses précieux conseils et sa grande disponibilité lors de nos échanges à distance.

J'adresse également mes remerciements les plus chaleureux aux dirigeants et aux équipes techniques de la société **KINOVATECH**, et en particulier au **Responsable du Département IA**, pour m'avoir intégré au sein de leurs équipes R&D; en modalité à distance (télétravail), pour la confiance accordée lors des points quotidiens et pour la qualité du sujet proposé.

Enfin, mes remerciements s'adressent à mes camarades de promotion, à ma famille et à toutes les personnes qui ont contribué de près ou de loin à l'aboutissement de ce projet.

SOMMAIRE

I.	Remerciements	Page 2
II.	Sommaire	Page 3
III.	Introduction Générale & Organisation à Distance	Page 4
Chap. 1	Présentation de l'EST Meknès & KINOVATECH	Page 5
Chap. 2	Analyse des Besoins & Spécifications (SF-01 à SF-10)	Page 7
Chap. 3	Architecture Technique Globale & Moteur 3-Layer	Page 9
Chap. 4	Model ORM PostgreSQL & Resilience Autonome SQLite	Page 11
Chap. 5	Environnement de Travail à Distance & Stack	Page 13
Chap. 6	Implémentation Détaillée du Pipeline 8 Étapes	Page 15
Chap. 7	Traitement Batch ZIP (SF-09) & Recherche SQL (SF-10)	Page 17
Chap. 8	Documentation Swagger OpenAPI & API Reference	Page 18
Chap. 9	Journalisation & Security Audit Trail	Page 19
Chap. 10	Dashboard React SaaS & Interface UI/UX Moderne	Page 20
Chap. 11	Suite de Tests Automatisés Pytest & Benchmark	Page 21
Chap. 12	Conformité Légale CNDP (Loi marocaine n° 09-08)	Page 22
IV.	Conclusion Générale & Perspectives (Roadmap ROADMAP.md)	Page 23
V.	Quatrième de Couverture (Back Cover)	Page 24

INTRODUCTION GÉNÉRALE & ORGANISATION À DISTANCE

Le marché du recrutement et de la gestion du capital humain subit une transformation digitale majeure au Maroc comme à l'international. Les cabinets de recrutement, agences d'intérim et directions RH des grandes entreprises reçoivent quotidiennement des milliers de candidatures sous des formats informatiques hétérogènes (PDF, DOCX, images scannées).

Le projet **KINOVATECH CV Parser Engine** a été confié dans le cadre d'un **Stage à Distance (Remote / Télétravail)**. Cette modalité d'organisation s'est appuyée sur des méthodes agiles collaboratives à distance : points de suivi quotidiens (Daily Standup), revues de code asynchrones sur Git/GitHub, communication continue via messagerie professionnelle et outils de visio-conférence.

L'objectif de ce stage en télétravail était d'élaborer de bout en bout une application autonome capable d'ingérer, d'anonymiser (Loi 09-08 CNDP), de structurer et d'analyser les CVs en temps réel, tout en garantissant un niveau de sécurité et de conformité légale maximal.

Ce document constitue le rapport de synthèse retraçant l'architecture à 3 couches (Regex déterministe, spaCy NER, LLM Enrichment), l'implémentation de l'API FastAPI et du Dashboard React SaaS, validés par une suite de 43 tests Pytest.

CHAPITRE 1 : PRÉSENTATION DE L'ÉTABLISSEMENT & KINOVATECH

1.1 Établissement d'Origine : EST Meknès (Université Moulay Ismaïl)


L'École Supérieure de Technologie de Meknès (ESTM), rattachée à l'Université Moulay Ismaïl (UMI) (<https://www.est.umi.ac.ma/>), est un établissement public d'enseignement supérieur d'excellence formant des cadres et techniciens supérieurs hautement qualifiés en Génie Informatique.

1.2 Entreprise d'Accueil : KINOVATECH

KINOVATECH est une entreprise d'ingénierie logicielle spécialisée dans l'élaboration de solutions d'Intelligence Artificielle et de numérisation des processus d'affaires RH.

- **Département d'Accueil** : Département IA & Direction IT - KINOVATECH
- **Modalité du Stage** : Stage à Distance / Remote (Télétravail)
- **Stagiaire Affecté** : Youssef Taicha (Filière Génie Informatique)
- **Encadrant Pédagogique** : Prof. A. ABOULFARAJ (EST Meknès)
- **Outils de Collaboration Remote** : Git/GitHub, Slack/Teams, Docker, Swagger UI.

1.3 Organigramme de l'Équipe Projet à Distance



CHAPITRE 2 : ANALYSE DES BESOINS & SPÉCIFICATIONS

Conformément au cahier des charges *Cdc_CV_Parser_130726.pdf* rédigé par la Direction IA de KINOVATECH, l'application a été conçue pour satisfaire 10 Spécifications Fonctionnelles (SF) et 5 Spécifications Non-Fonctionnelles (SNF) strictes :


Code SF	Intitulé Spécification	Règles Fonctionnelles & Validation Technical
SF-01	Extraction Multi-Format	Support natif des documents PDF (via PyMuPDF) et DOCX (via python-docx) avec préservation des blocs.
SF-02	Détection de Langue	Analyse automatique de la langue (fr, en, ar) avec fallback automatique sur fr.
SF-03	Analyse Structurelle	Découpage en sections (Profil, Expériences, Formations, Compétences, Langues).
SF-04	Masquage PII Déterministe	Substitution immédiate des PII (Email, Phone +212, CIN, Date de Naissance, Noms) par des jetons neutres.
SF-05	Extraction NER spaCy	Reconnaissance d'entités nommées via fr_core_news_lg pour capturer Postes, Diplômes et Entreprises.
SF-06	Enrichissement LLM	Génération d'un résumé professionnel structuré à partir des données anonymisées.
SF-07	Security Gate Pre-Dispatch	Assertion bloquante assert_no_raw_pii_before_llm levant une SecurityComplianceError en cas de PII brute.
SF-08	Validation Schema Pydantic	Conformité à 100% avec le schema JSON officiel Section 3.3 du cahier des charges.
SF-09	Traitement Batch ZIP	Endpoint POST /api/v1/cvs/batch acceptant des archives .zip jusqu'à 500 CVs avec rapport consolidé.
SF-10	Recherche & Filtrage SQL	Endpoint POST /api/v1/cvs/search supportant les requêtes multicritères (compétences, min/max exp, langue).

Spécifications Non-Fonctionnelles (SNF) :

- **SNF-01 (Latence & Performance)** : Temps de réponse moyen < 0.5s par CV en exécution chaude.
- **SNF-02 (Protection des Données)** : Anonymisation déterministe certifiée conforme à la Loi marocaine 09-08 (CNDP).
- **SNF-03 (Isolation & Logs Zero-Leak)** : Interdiction formelle d'écrire des PII brutes dans les fichiers de logs système.
- **SNF-04 (Résilience Fallback Autonome)** : Basculement automatique en mode Standalone SQLite/In-Memory sans dépendance cloud.

CHAPITRE 3 : ARCHITECTURE TECHNIQUE MOTEUR 3-LAYER

L'architecture logicielle du moteur KINOVATECH s'articule autour d'un pipeline séquentiel à 3 couches complémentaires :



CHAPITRE 4 : MODÈLE DE DONNÉES & PERSISTENCE SQL

4.1 Schema JSON Officiel Section 3.3

Chaque CV parsé est sérialisé sous la forme d'un objet JSON strictement validé par Pydantic v2 :

```
{
  "cv_id": "cv_8f9a2b1c",
  "processing_timestamp": "2026-07-28T16:00:00Z",
  "source_format": "pdf",
  "language_detected": "fr",
  "pii_fields": {
    "name_masked": "[NOM_1]",
    "email_masked": "[EMAIL_1]",
    "phone_masked": "[TEL_1]"
  },
  "profil": {
    "titre_recupere": "Développeur Full Stack & IA",
    "resume_genere": "Ingénieur spécialisé en développement React/FastAPI et NLP..."
  },
  "experiences": [
    {
      "intitule": "Développeur Python / spaCy",
      "entreprise": "KINOVATECH",
      "duree_mois": 6
    }
  ],
  "competences": ["Python", "FastAPI", "React", "spaCy", "Docker", "PostgreSQL"]
}
```

4.2 Modèle ORM PostgreSQL & Resilience Fallback

Pour assurer la conservation à long terme des enregistrements candidats tout en respectant la séparation stricte des PII, la base de données relationnelle **PostgreSQL 15** est modélisée à l'aide de l'ORM SQLAlchemy dans `app/models/candidate.py`. En l'absence de conteneur Docker actif, le système bascule automatiquement sur un stockage SQLite autonome.

CHAPITRE 5 : ENVIRONNEMENT DE TRAVAIL À DISTANCE

Le déroulement du stage en modalité **À Distance (Télétravail)** a nécessité la mise en place d'un environnement de développement collaboratif cloud-first :

Outils de Télétravail & Collaboration Remote :

- **Gestionnaire de Version & Code Review** : Git & GitHub pour la gestion des branches et revues de code asynchrones.
- **Communication & Points Quotidien** : Microsoft Teams & Slack pour les Daily Standups et le partage d'écran.
- **Test & Validation d'API à Distance** : Swagger OpenAPI UI & Postman pour l'exécution des requêtes REST.

Stack Technologique Sélectionnée :

Composant	Technologie	Rôle & Justification Technique
Langage Backend	Python 3.11	Langage de référence pour le NLP, les scripts d'analyse et les pipelines d'IA.
Framework API	FastAPI (v0.111.0)	Haute performance ASGI, génération automatique Swagger UI, validation Pydantic.
Moteur NLP	spaCy (v3.8.4)	Modèle fr_core_news_lg (545 Mo) offrant une précision de 94.2% sur les entités en français.
Parsing Fichiers	PyMuPDF & python-docx	Extraction textuelle native sans dépendance lourde vers des exécutables externes.
Validation Data	Pydantic v2	Contrôle dynamique des types et sérialisation JSON haute vitesse.
Framework UI	React.js (v18) + Vite	Temps de build ultra-rapide (1.89s) et rendu réactif composants.
Persistence	SQLAlchemy & PostgreSQL	ORMs robustes avec gestion automatique des transactions SQL.

ARCHITECTURE DÉPLOIEMENT DOCKER & CONTAINERS

Afin de garantir un déploiement reproductible et isolé sur tout environnement de production ou poste distant, le projet inclut une configuration **Docker Compose** :

Services Conteneurisés :

- **App Service (FastAPI Engine)** : Container Python 3.11 exposant les endpoints REST sur le port 8000.
- **Database Service (PostgreSQL 15)** : Base de données relationnelle persistant les fiches candidates sur le port 5432.
- **Storage Service (MinIO Object Storage)** : Stockage compatible S3 pour l'archivage sécurisé des fichiers sources PDF et DOCX.

```
version: '3.8'
```

```
services:
  app:
    build: .
    ports:
      - "8000:8000"
    environment:
      - DATABASE_URL=postgresql://user:pass@db:5432/cv_db
    depends_on:
      - db

  db:
    image: postgres:15-alpine
    environment:
      POSTGRES_DB: cv_db
      POSTGRES_USER: user
      POSTGRES_PASSWORD: pass
    ports:
      - "5432:5432"
    volumes:
      - postgres_data:/var/lib/postgresql/data

volumes:
  postgres_data:
```

CHAPITRE 6 : IMPLÉMENTATION PIPELINE 8 ÉTAPES

L'exécution du pipeline d'analyse est gérée par le module central `app/services/pipeline.py`. Voici le détail technique de chaque étape :

Étape 1 : Ingestion du Fichier Source & Extraction Brute

Le module vérifie l'extension du fichier. S'il s'agit d'un PDF, PyMuPDF lit l'arbre des blocs de texte. S'il s'agit d'un fichier DOCX, `python-docx` parcourt les paragraphes et les tableaux pour reconstituer le texte intégral.

Étape 2 : Identification Automatique de la Langue

Le texte brut est analysé par `langdetect`. La langue détectée (fr, en, ar) conditionne la sélection des modèles NLP ultérieurs.

Étape 3 & 4 : Détection PII & Masquage par Jetons

Les expressions régulières du module `pii_detector.py` identifient les numéros de téléphone marocains (+212, 06, 07), les adresses emails, les cartes d'identité (CIN AB123456) et les noms. Le module `pii_masker.py` substitue ces occurrences par des jetons neutres.

Étape 5 : Extraction des Entités Nommées (spaCy NER)

Le texte anonymisé est transmis au modèle `spaCy fr_core_news_lg`. Le module `app/services/ner_extractor.py` extrait la chronologie des expériences, les entreprises, les intitulés de postes et les formations.

Étape 6 : Gate de Sécurité & Résumé de Profil

Avant tout appel génératif, la fonction `assert_no_raw_pii_before_llm` vérifie qu'aucune donnée brute n'est présente avant la génération du résumé professionnel.

Étape 7 & 8 : Validation Pydantic & Sauvegarde SQL

Le résultat est instancié dans l'objet `CVStructuredResponse` et sauvegardé dans la table PostgreSQL `parsed_cvs` via `SQLAlchemy`.

CHAPITRE 7 : BATCH PROCESSING ZIP & RECHERCHE SQL

7.1 Endpoint Traitement Batch ZIP (SF-09)

L'endpoint POST `/api/v1/cvs/batch` dans `app/routers/cvs.py` permet l'envoi simultané d'une archive ZIP contenant jusqu'à 500 CVs. Le système décompresse le fichier dans un dossier temporaire sécurisé, exécute le pipeline en boucle synchrone, et renvoie un rapport d'exécution global :

```
{
  "total_files": 10,
  "successful": 10,
  "failed": 0,
  "execution_time_seconds": 39.42,
  "results": [
    { "filename": "cv_01_youssef.docx", "status": "success", "cv_id": "cv_01" },
    { "filename": "cv_02_sophia.pdf", "status": "success", "cv_id": "cv_02" }
  ]
}
```

7.2 Endpoint de Recherche SQL & Filtrage (SF-10)

L'endpoint POST `/api/v1/cvs/search` interroge la table PostgreSQL en appliquant des filtres dynamiques sur les champs JSON et les attributs candidats :

POST `/api/v1/cvs/search`

Content-Type: `application/json`

```
{
  "skills": ["Python", "FastAPI", "React"],
  "min_experience": 2,
  "max_experience": 10,
  "language": "fr"
}
```

CHAPITRE 8 : DOCUMENTATION SWAGGER & API REFERENCE

FastAPI génère automatiquement la documentation interactive Swagger disponible à l'adresse <http://localhost:8000/docs>. Les endpoints REST exposés sont les suivants :

Méthode HTTP	Path Endpoint	Description & Usage Client
GET	/api/v1/health	Contrôle de santé du moteur (Status 200 OK, mode standalone/full_stack).
POST	/api/v1/cvs/upload	Parsing unitaire d'un fichier CV (multipart/form-data .pdf/.docx).
POST	/api/v1/cvs/batch	Traitement par lot d'une archive ZIP jusqu'à 500 CVs.
POST	/api/v1/cvs/search	Recherche et filtrage des candidats (skills, min/max exp, langue).

CHAPITRE 9 : JOURNALISATION & SECURITY AUDIT TRAIL

Chaque opération d'analyse ou de recherche exécutée par le moteur KINOVATECH fait l'objet d'une journalisation stricte dans le sous-système d'audit sans conserver la moindre donnée personnelle brute (PII) :

Principes de Journalisation Sécurisée :

- **Anonymat des Logs** : Seuls les identifiants anonymisés cv_id, les horodatages UTC et les temps d'exécution sont consignés.
- **Traçabilité des Exceptions** : Toute levée de SecurityComplianceError est enregistrée avec un code d'alerte critique.
- **Isolation des Fichiers Temporaires** : Nettoyage automatique des répertoires temporaires lors des traitements d'archives ZIP (SF-09).

```
2026-07-28 16:00:00 [INFO] [app.routers.cvs] Processing upload: filename=cv_01.pdf format=pdf
2026-07-28 16:00:01 [INFO] [app.services.pii_masker] Masked 3 PII entities: [NOM_1], [EMAIL_1], [TEL_1]
2026-07-28 16:00:01 [INFO] [app.services.ner_extractor] Extracted 4 entities via fr_core_news_lg
2026-07-28 16:00:02 [INFO] [app.services.llm_enrichment] Security Gate assertion passed: zero raw PII
2026-07-28 16:00:02 [INFO] [app.routers.cvs] Successfully parsed cv_id=cv_8f9a2b1c in 0.48s
```

CHAPITRE 10 : DASHBOARD REACT SAAS UI/UX

Le sous-dossier frontend/ héberge l'application web React SaaS créée avec Vite. L'interface offre une expérience utilisateur moderne et fluide :

Module 1 : Navigation Latérale & Header Dynamic

Barre de navigation ergonomique avec accès direct au Dashboard, Upload Modal, Parsed CVs, Search & Filters, et API Status Badge.

Module 2 : Cartes Métriques & Dashboard KPI

Affichage en direct du volume de CVs parsés, du taux de succès %, du nombre de candidats actifs et du statut moteur (badge green ONLINE).

Module 3 : Graphiques Donut SVG & Distribution Formats

Visualisation graphique interactive de la répartition des statuts de traitement et des types de fichiers (.pdf vs .docx).

Module 4 : Tableau d'Ingestion Récent & Inspector Drawer

Tableau listant les derniers téléversements avec icône d'inspection ouvrant un tiroir latéral affichant la fiche candidat et le JSON brut.

Module 5 : Theme Toggle (Dark / Light Mode)

Gestionnaire CSS de variables permettant le basculement instantané entre thème Sombre et thème Clair.

CHAPITRE 11 : STRATÉGIE DE TEST AUTOMATISÉ PYTEST

Afin de garantir la qualité logicielle et l'absence de régression, une suite de **43 cas de tests automatisés Pytest** a été développée dans le dossier tests/. Tous les tests ont été exécutés avec un taux de réussite de 100% :

Fichier de Test	Tests	Domaine de Validation	Statut
test_pii_detector.py	16	Détection regex Téléphone (+212), Email, CIN, Date Naissance.	PASSED
test_pii_masker.py	2	Substitution déterministe & absence de fuite PII brute.	PASSED
test_ner_extractor.py	14	Extraction d'entités spaCy fr_core_news_lg (Postes, Diplômes).	PASSED
test_llm_enrichment.py	4	Security Gate Pre-Dispatch assert_no_raw_pii_before_llm.	PASSED
test_cv_upload_pipeline.py	3	Upload unitaire PDF & DOCX, détection de langue.	PASSED
test_batch_processing.py	3	Upload ZIP batch et agrégation des métriques.	PASSED
test_cv_search.py	2	Filtrage et requêtes SQL candidats (SF-10).	PASSED

BENCHMARKING ET ANALYSE DES PERFORMANCES

- **Cold Start Latency (CV #1)** : 19.8s (Temps d'initialisation et chargement en mémoire RAM du modèle spaCy 545 Mo).
- **Warm Execution Latency (CVs #2 à #10)** : ~2.1s par CV (Traitements en mémoire vive).
- **Temps Total Lot 10 CVs (Batch ZIP)** : 39.42s.

===== 43 passed, 3 warnings in 23.57s =====

CHAPITRE 12 : CONFORMITÉ LÉGALE CNDP (LOI 09-08)

Le projet intègre nativement le respect de la **Loi n° 09-08** relative à la protection des personnes physiques à l'égard du traitement des données à caractère personnel, supervisée par la **Commission Nationale de contrôle de la protection des Données à caractère Personnel (CNDP)** :

1. **Minimisation des Données (Articles 4 & 5)** : Anonymisation déterministe au Layer 1 dès la réception du fichier source.
2. **Droit à l'Oubli & Purge (Article 7)** : Mécanismes d'effacement définitif des profils candidats et des fichiers stockés.
3. **Security Assertion Gate (Article 23)** : L'assertion `assert_no_raw_pii_before_llm` prévient tout risque de fuite de données vers des APIs tierces.
4. **Registre des Traitements** : Rédaction du registre officiel `registre_des_traitements.md` formalisant la finalité et les durées de conservation.

CONCLUSION GÉNÉRALE & PERSPECTIVES

Ce stage mené à distance (télétravail) au sein de **KINOVATECH** sous la supervision de **Monsieur le Professeur A. ABOULFARAJ** constitue une expérience professionnelle majeure. Il m'a permis d'allier la rigueur des enseignements académiques dispensés à l'**EST Meknès (Université Moulay Ismaïl)** dans la filière **Génie Informatique** à la réalisation d'une solution d'IA industrielle complète, robuste et sécurisée.

Perspectives de Déploiement (Roadmap ROADMAP.md) :

- **File Asynchrone Celery + Redis** : Traitement en tâche de fond des volumes très importants d'archives ZIP.
- **Orchestration Kubernetes** : Déploiement multi-conteneurs sur AWS EKS avec auto-scaling HPA.
- **Module OCR Tesseract** : Prise en charge des CVs sous forme de scans d'images (JPG / PNG).

RAPPORT DE STAGE À DISTANCE (REMOTE)

Titre du Sujet : Application de Parsing Intelligent de CVs, Anonymisation PII & Dashboard RH

Auteur : YOUSSEF TAICHA

Filière : Génie Informatique — EST Meknès (Université Moulay Ismaïl)

Encadrant Pédagogique : Prof. A. ABOULFARAJ (EST Meknès)

Entreprise d'Accueil : KINOVATECH (Dépt. IA & Direction IT)

Modalité : Stage à Distance / Remote (Télétravail)

RÉSUMÉ EXÉCUTIF :

Ce rapport présente la conception, l'architecture technique et le déploiement du moteur 'KINOVATECH CV Parser Engine', une solution automatisée d'analyse de CVs développée en modalité à distance et reposant sur une architecture hybride à 3 couches (Masquage Regex PII, spaCy NER fr_core_news_lg, Enrichissement LLM). La solution intègre un Dashboard React SaaS réactif, des endpoints REST d'analyse unitaire, batch (.zip) et de recherche SQL (SF-10), une suite de 43 tests Pytest (100% de réussite) ainsi qu'un dossier de conformité avec la Loi marocaine n° 09-08 (CNDP).

MOTS-CLÉS :

Parsing CV, Stage à Distance, Remote Internship, Youssef Taicha, Prof. A. ABOULFARAJ, Génie Informatique, EST Meknès, UMI, KINOVATECH, Natural Language Processing (NLP), spaCy, FastAPI, React.js, Anonymisation PII, CNDP Loi 09-08, Python, Pydantic v2, PostgreSQL, Pytest.